

110 學年度專題報告競賽

題目: 運用統計模型與分類器分辨
帕金森氏患者產生步態凝凍與步態凝凍前的狀態

系所班別: 統計系三年級

姓名學號: 嚴潔翎(410878043)

柯怡瑄(410878049)

黃承平(410878021)

賴仁凱(410878045)

許弘叡(410878008)

葉于廷(410878048)

報告日期: 2022/06/10

摘要

帕金森氏患者晚期會頻繁出現凝凍步態，高度影響病患的行走能力，甚至導致跌倒與受傷，目前對於此症狀採取人工辨識且沒有藥物能完全治療凝凍步態，如果可以預測凝凍步態並提示將要發作的患者便能大幅提升他們的生活品質與改善行動能力。

本研究從公開資料所收集帕金森氏患者在三個部位 (大腿，軀幹，腳踝) 穿戴加速度感測儀的步態資料，透過特徵擷取總共 508 個特徵，並從最小冗餘最大特徵法 (Minimum redundancy feature selection)、Relief F 和互資訊 (Mutual information) 中，選出最佳的維度縮減方法，與較能辨識凝凍步態的資料，本次研究以統計的角度，針對資料的特性配適樣條函數特徵，並使用統計方法審視各個部位對於辨識凝凍步態的貢獻，與評估使用維度縮減的合理性，最後得出最有效的辨識凝凍步態的模型，接著，從支援向量機 (SVM)、羅吉斯迴歸 (Logistic Regression)、隨機森林 (Random Forest)、k-近鄰分類器 (KNN)、單純貝氏 (Naive Bayes) 和 RUSBoost 挑選出合適的分類器來辨識與預測凝凍步態。

參考其他文獻設定凝凍步態發生狀態，本研究最適合的凝凍步態標籤設定是從凝凍步態發生前兩秒開始到發生結束，而預測是從凝凍步態發生前兩秒到剛要發生時。

對於凝凍步態的辨識與預測，以隨機森林的模型表現最好，辨識凝凍步態整個過程可達靈敏度 89% 和特異度 92%、從前兩秒開始預測的凝凍步態也可達到靈敏度 96% 和特異度 88%。另一方面，在患者只穿戴軀幹的感測儀時，辨識凝凍步態可達到 88% 的準確度。此外，在減少穿戴的感測儀下還能近乎九成辨識凝凍步態，研究中分類器優異表現在引入提示聲後能改善帕金森氏症患者的日常活動以及給予生活自主的能力。

1 前言

帕金森氏症是繼阿茲海默症後，全球第二常見的神經退化疾病，會伴隨身體僵硬與失眠的情況，據 Parkinson's Foundation 統計 [1]，全世界有超過 1000 萬人罹患帕金森氏症，且患病人數因人口老化日益增長。已知帕金森氏症的發病率會隨著年齡的增長而增加，60 歲以上每增加一歲，盛行率便提高 1 %；80 歲以上則每增加一歲，盛行率上升 4 %。據內政部統計 [2]，在臺灣，民國 110 年我國老年人口 (65 歲以上) 393.9 萬人，相較前一年增加約 15.1 萬人，上升 4 %，隨著老年人口基數增加，罹病患者會日益增多，其中目前健保統計因帕金森氏症就醫的患者共 77428 人，約占老年人口的 2 % [3]，相當於在一百位六十五歲以上的年長者中，平均有兩位是帕金森氏症患者。嚴重的是，到了病徵的

晚期，病患會開始有行走與溝通的困難，甚至開始有容易感到疲倦、憂鬱等心理問題，需要長照的他們日漸為社會帶來龐大的社會成本。隨著病患占世界人口比例的漸增，間接加重了生產者的經濟與勞力負擔，影響的雙方的生活品質。

凝凍步態是帕金森氏症的病徵，此症狀發作時，病患雙腿無法向前邁步，待在原地顫抖，在回復到正常狀態前，病患急需他人攙扶或支撐以保持平衡。此症狀很容易在患者身處人群時發生。例如上下火車時，人群在車門附近迅速地聚集會使病患情緒不穩，間接影響病徵的出現，此刻病患突然無法行動是非常危險的，推擠與催促使病患更加緊張，愈無法緩解病徵，大幅增加受傷的機會。現今對於凝凍步態發作尚未有一個明確的定義，目前是依人工觀察來判斷症狀是否發生，但這並非是長遠之計，長期觀察一個人症狀發生時的特徵並時刻注意他的安危，不僅消耗社會資源，也容易造成患者的心理負擔。此研究的目的是期望能讓帕金森氏症的患者能夠盡可能擁有自主生活的能力。

隨著資料收集技術與機器學習理論的成熟，已經可以將凝凍步態問題導入人工智慧中，透過攜帶式裝置收集病人的步態資料，並加以訓練人工智慧，偵測出步態的異常，甚至可在凝凍步態前辨識到跡象，讓病患可以提前做好準備。未來將裝置導入實際生活獲取大量步態資料後即能完整的訓練模型，得到更精確的判斷，並在發生病徵時，發出提示聲提醒病患與周遭的人，除了病患能夠知道本身正在發作凝凍步態，他人也能較易觀察異樣在旁提供協助，使病患免於跌倒受傷的風險，擁有更完善的生活品質，同時減輕醫療照護負擔，舒緩社會壓力。

2 文獻回顧

很多學者研究過使用非人工的方法辨識、預測凝凍步態，其中不乏各種機器學習的方法。Pardoel, 等人 (2021) 使用足底壓力、腳踝與大腿三軸加速度和角速度資料，配合決策樹 (decision tree) 和隨機下取樣演算法 (RUSBoost)，對前凝凍步態與凝凍步態的偵測達到 85% 靈敏度和 94% 特異度。[4] Pham, 等人 (2017) 使用腳踝、大腿與軀幹的三軸加速度和他們的異常檢測演算法對凝凍步態與非凝凍步態做分類，得到 87.5 % 的靈敏度，84.5 % 的特異度。[5] Kleanthous, 等人 (2020) 使用腳踝、大腿、軀幹的三軸加速度，配合支援向量機 (SVM)，對凝凍步態、凝凍步態過渡期和無凝凍步態進行三種分類，分別達到 72%，91%，75% 的靈敏度和 87%，88%，93% 的特異度。[6] Li, B., 等人 (2020) 同樣使用腳踝、大腿、軀幹的三軸加速度，並使用深度卷積神經網路和長短期記憶模型分辨凝凍步態和非凝凍步態，達到 95% 靈敏度和 98% 特異度。[7] Shalin, 等人 (2020) 將足底壓力資料輸入卷積神經網路，對凝凍步態、前凝凍步態和無凝凍步態進行三種分

類，分別達到 92%，94%，92% 靈敏度，96%，95%，98% 特異度。[8] 在種種文獻中，儘管有部分研究使用相同資料集，但隨標籤的定義、使用的特徵和分類器的異同，辨識凝凍步態的成效也大相逕庭。

3 研究方法及步驟

3.1 資料來源

實驗資料 [9] 是來自於加利福尼亞大學爾灣分校 (University of California-Irvine) 所建構的 UCI 資料庫系統中心。這個實驗為帕金森氏症患者的行走實驗，實驗室中會記錄病人的步態資料，分別要求好發凝凍步態的受試者在各個部位穿戴內建微型電腦的加速度感測儀（綁在腳踝、大腿以及臀部）後，沿著研究路徑進行十分鐘實驗，其中動作包括隨意走動、轉彎和停止，並記錄水平橫向、水平前後和垂直方向的加速度。過程中，凝凍步態的辨別是依照身旁物理治療師的觀察。在實驗過程中，加速度感測器會以 64 Hz 的頻率紀錄資料。資料分類分成三類，分別為不屬於實驗範圍的動作 (資料中以 0 來表示)、沒有發生凝凍步態 (資料以 1 來表示) 和發生凝凍步態 (資料以 2 來表示)。

3.2 資料視窗切割

收集完的資料為單一時點的加速度資料，而為了觀察出較完整的行動軌跡，我們將多個資料點整併為一個視窗，視為一個樣本，並採用滑動視窗法 (Sliding Window)。參考 Bachlin [10]，將資料的視窗定義成 4 秒一個視窗，且兩個相鄰視窗間的重疊時間為 3.5 秒，即視窗一次滑動 0.5 秒。為了增加樣本數，我們縮短每個視窗的時間，將視窗持續時間定義為 1 秒一個視窗，且兩個相鄰視窗的重疊時間調整為 0.75 秒，即一次滑動時間為 0.25 秒。

3.3 凝凍步態標籤定義

3.3.1 凝凍步態四類視窗定義

Pardoel [4] 將視窗分為四種狀態：無凝凍步態 (No-FOG)、凝凍步態前 (Pre-FOG)、凝凍步態過渡期 (Pre-FOG Transition)、凝凍步態 (FOG)，在廣義的分類中，後三種都屬凝凍步態。凝凍步態事件的前兩秒稱做前凝凍步態片段 (Pre-FOG segment)，發生期間稱做凝凍步態片段 (FOG segment)，其他期間稱之為無凝凍視窗片段 (No-FOG segment)。完整視窗落前凝凍步態片段中在被定義為前凝凍步態 (Pre-FOG)，例如圖 1 中的 W 7 - W

11, 若視窗的開頭落在前凝凍步態片段, 結束落在凝凍步態片段中, 則視窗被分類為凝凍步態過渡期 (Pre-FOG transition), 如圖 1 中的 W 12 - W 16, 視窗完整落在凝凍步態片段中則被分類為凝凍步態 (FOG), 如圖 1 中的 W 17, 其餘的視窗則被分類為無凝凍步態 (No-FOG)。




圖 1: 視窗定義示意圖 (摘錄自 [4])

3.3.2 目標和非目標類定義

為較簡易的評估預測與辨別成效, 我們將四類的視窗再進一步定義為兩類 (目標類別與非目標類別)。辨別類的目標類別蒐集所有關於凝凍步態的訊息, 即前凝凍步態、凝凍步態過渡期和凝凍步態, 並將無凝凍步態定為非目標類, 而預測類的目標類別納入凝凍步態發生前的徵兆為前凝凍步態和凝凍步態過渡期, 並視無凝凍步態定為非目標類, 參照表 1。

表 1: 判斷與預測凝凍步態類別之分類

	目標類別	非目標類別
辨別類	前凝凍步態 + 凝凍步態過渡期 + 凝凍步態	無凝凍步態
預測類	前凝凍步態 + 凝凍步態過渡期	無凝凍步態

3.4 特徵擷取

根據 [4], [10], [11] 與樣條函數所產生特徵, 視窗的特徵值可大致分為三種。第一種, 原始加速度得到的敘述性統計。另外, 因為三個部位各有三軸, 所以以下特徵值除了平均

加速度能量 (AAE) 外都是衍伸出 9 個特徵值，而平均加速度能量 (AAE) 則為 3 個特徵值。第二種，原始資料經傅立葉轉換後得到的數值，根據文獻所得特徵值，故總共有 129 個。第三種，有別於其他論文，利用樣條函數配適加速度資料點，估計出合適的軌跡，取出 B-樣條 (B-spline) 基底的座標為特徵和自然三次樣條的每段的方程式係數作為特徵，共有 396 個特徵。特徵詳細介紹請見[附錄 A](#)。

3.5 維度縮減

使用下述三種方法，進行維度縮減。

1. Relief f
2. 互資訊 (Mutual Information, MI)
3. 最小冗餘最大特徵法 (minimum-redundancy maximum-relevance, mRMR)

詳細方法請見[附錄 B](#)。

3.6 模型開發

3.6.1 分類器模型介紹

本研究使用下述六種分類器。

1. 支援向量機 (SVM)
2. 隨機森林 (Random forest)
3. RUSboost
4. 單純貝氏 (Naive bayes)
5. K-近鄰演算法 (KNN)。
6. 羅吉斯回歸 (Logistic Regression)

詳細方法請見[附錄 C](#)。

3.6.2 評估指標

綜合模型的表現可分成下列四個部分：真陽性 (True Positive, TP) 代表為該視窗實際為凝凍步態且預測該視窗亦為凝凍步態；真陰性 (True Negative, TN) 代表為該視窗實際為非凝凍步態且預測該視窗亦為非凝凍步態；偽陰性 (False Negative, FN) 代表該視窗實際為凝凍步態且預測該視窗為非凝凍步態；偽陽性 (False Positive, FP) 該視窗實際為非凝凍

步態且預測該視窗為凝凍步態，並依此建構各項評估指標，評估分類器的表現之優劣，參照表 2。

表 2: 評估指標

評估指標	定義	描述
靈敏度 (Sensitivity)	$TP/(FN+TP)$	評估真實狀態為陽性其預測結果亦為陽性的比率
特異度 (Specificity)	$TN/(FP+TN)$	評估真實狀態為陰性其預測結果亦為陰性的比率
準確度 (Accuracy)	$(TP+TN)/(TP+FP+TN+FN)$	測量分類正確占整體的比率



圖 2: 研究流程圖

4 研究結果

4.1 資料狀況




圖 3: 十位病患凍凝步態持續時間直方圖

評估這份資料是否符合合適的收集，我們將每位病患的凝凍步態持續時間記錄下來，並繪製直方圖 (圖 3)，病患發生凝凍步態的時間 50 % 是小於 5.4 秒的，與 J. D. Schaafsma 研究 [12] 一致，此分布是類似病患早期凝凍步態的狀況，因此我們認定這資料的搜集是成功的。

表 3: 十位病患凝凍步態分類頻率表

病患代碼	無凝凍步態	凝凍步態	凝凍步態過渡期	前凝凍步態
01	12248 (96.1%)	332 (2.6%)	80 (0.6%)	88 (0.7%)
02	9323 (92.02%)	632 (6.2%)	92 (0.9%)	84 (0.8%)
03	14492 (91.6%)	956 (6%)	198 (1.3%)	170 (1.1%)
04	12230 (100%)			
05	11013 (83.7%)	1640 (12.5%)	256 (1.9%)	248 (1.9%)
06	13171 (95.9%)	488 (3.6%)	39 (0.3%)	41 (0.3%)
07	10205 (96.2%)	228 (2.1%)	87 (0.8%)	89 (0.8%)
08	7672 (89.9%)	749 (8.8%)	54 (0.6%)	58 (0.7%)
09	9591 (89.1%)	975 (9.1%)	100 (0.9%)	100 (0.9%)
10	12078 (100%)			
全部病患	112023 (94%)	6000 (5%)	906 (1%)	878 (1%)

以四個類別定義視窗，可以切割為 112023 個無凝凍步態視窗、6000 個凝凍步態視窗、906 個凝凍步態過渡期視窗和 878 個前凝凍步態視窗，參照表 3。此外，病患 10 和病患 4 的視窗只能分類成無凝凍步態，意味著兩位受試者在實驗當下沒有發生凍凝步態。另一方面，每人凍凝步態視窗數量會因凍凝步態發生次數的不一而差異很大，像是病患 7 只有 228 個凍凝步態視窗，而病患 5 則是病患 7 的近 7 倍，共有 1640 個凍凝步態視窗。

視窗分為四類後，我們進一步分類成兩類，較易觀察模型的結果，而辨識類與預測類的目標視窗數與非目標視窗卻有極大的差異。辨識類的目標類 (前凝凍步態、凝凍步態過渡期和凝凍步態) 共 7784 (6000 + 906 + 878) 個視窗。非目標類 (無凝凍步態) 共 112023 個視窗。預測類目標類 (前凝凍步態、凝凍步態過渡期) 共 1784 (906 + 878) 個視窗。非目標類 (無凝凍步態) 共 112023 個視窗。

4.2 交叉驗證法 (Cross validation)

檢視分類器是否穩定的預測與辨識凍凝步態，進而引入交叉驗證法。因凍凝步態 (目標類) 與非凍凝步態 (非目標類) 筆數懸殊，目標類占不到全部視窗 20 %，避免分類器產生偏誤，故先將資料平衡，取所有目標類視窗，再抽取目標類視窗數兩倍的非目標視窗。

將目標類與非目標類各採 70 % 合併為訓練集，測試集則為剩餘的各 30 % 合併，整理成較為平衡的資料集，參考圖 4。重複 30 次抽取非目標視窗，又因非目標類視窗遠超過目標類視窗，故每次抽取之視窗不一定相同，讓非目標類視窗之特徵能較完整的被訓練，共產生 30 個訓練集及 30 個測試集。




圖 4: 交叉驗證示意圖

4.3 原始加速度特徵與傅立葉變數特徵成效

我們蒐集以往論文中的特徵，藉以評估哪些較有可能是凝凍步態跡象的可能。主要分為兩大類分別是傅立葉特徵和加速度特徵。

4.3.1 合適的維度縮減方法與模型

維度縮減是從多個特徵中，找出其中較有代表性的特徵，不僅能加速模型的運算且不失辨識能力，也能說明哪些是利於辨識凝凍步態的關鍵資料。為此，我們將這些特徵進行維度縮減後，對辨識類的資料進行交叉驗證，分別討論每個模型配適辨識類的資料情形。維度縮減從一個到三十個特徵，固定維度縮減方法與數量下，進行辨識類資料的交叉驗證，再將 30 次測試的結果的準確度平均，而繪製出圖 5 上的其中一點的結果，而不同條線代表的是另一種維度縮減方法。

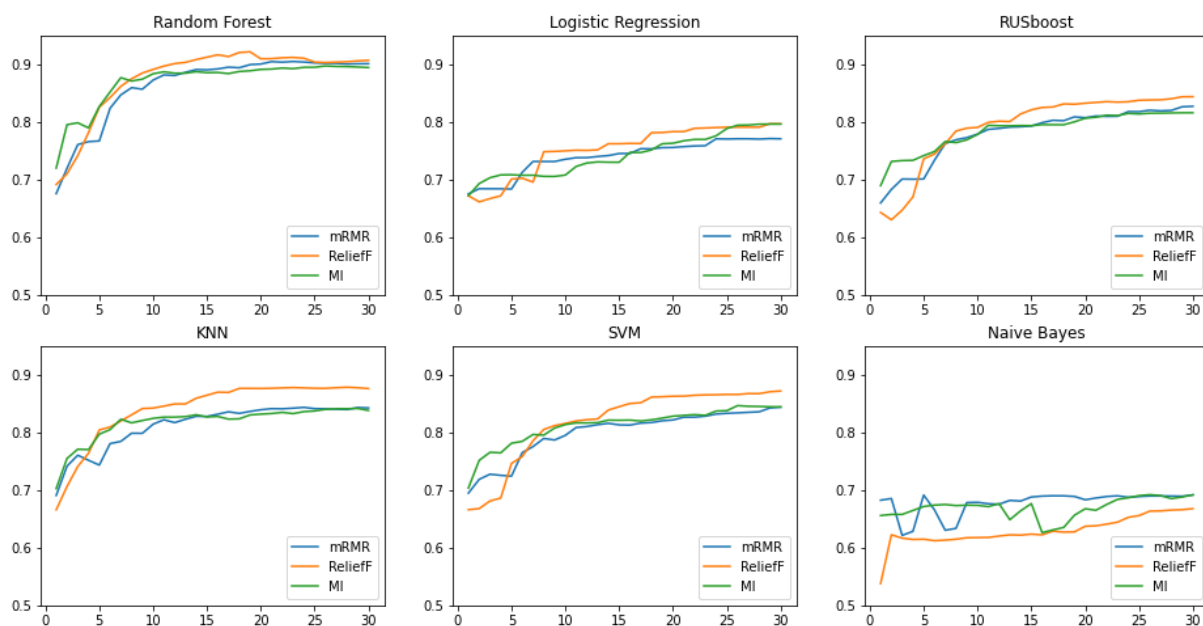


圖 5: 三種維度縮減在不同維度縮減數量各模型的平均準確度

一般的分類器會在特徵愈多時，表現會越好，即交叉驗證所得的 30 個準確度較高。圖 5 可印證此想法，一開始交叉驗證在特徵小於 20 時，平均準確度雖有小動盪但有愈來愈高的趨勢，而隨著特徵數目從 20 增加時，六個分類器平均準確度呈現緩慢上升的趨勢，因此我們認為 20 是維度縮減適合的特徵數量，進而比較模型之間的表現情況。此外，三個維度縮減方法中，除單純貝氏模型，另外五個模型在使用 Relief F 挑出 20 以上特徵的平均準確度會高於使用最小冗餘最大特徵法 (mRMR) 以及互資訊 (mutual information) 的平均準確度，因此我們選用 Relief F 最為此次研究的維度縮減方法。

對資料進行檢視後，我們認為這筆資料特徵違反單純貝氏的假設導致平均準確度大幅遠低於其他模型，之後的討論會忽略該模型，接著，討論剩下五個的模型維度縮減的合理性，分別是羅吉斯回歸、隨機森林、K-近鄰演算法、RUSboost、支援向量機，用所有特徵與 20 個特徵全用的交叉驗證平均準確度進行獨立樣本 t 檢定，檢視是否維度縮減前後是否有顯著差異的平均準確度。

最後，在維度縮減至 20 特徵的隨機森林模型有最高的平均準確度，大約 91 %，呈現出此資料可以因維度縮減能有更好的分類模型 (圖 6)。此外，KNN 與隨機森林模型在 Relief F 取 20 個特徵時，交叉驗證的平均準確度會顯著高於使用全部特徵進行訓練，而羅吉斯回歸、RUSboost、SVM 則得到顯相對低於的結果，代表如要進行維度縮減，使用 KNN 與隨機森林模型較為合適，不但計算加速且比特徵全用有更好的表現，也找到了較具有代表性的 20 個特徵，分別為原加速度的中位數、最大值和最小值以及傅立葉分析加速度的最大頻率。




圖 6: 相異模型維度縮減前後的準確度盒型圖

因 K-近鄰分類器與隨機森林的表現優於其他分類器，以下的分析僅討論兩種模型的結果，其餘分類器的表現，參見附錄 D。

4.3.2 交叉驗證的預測與辨識凝凍步態成效

訓練後的模型除了可以完整的辨識整個凝凍步態的過程，也希望可以在凝凍步態發生前就能成功預測。以下分別採用預測類及辨識類的資料集以及維度縮減 Relief f 取前 20 個特徵進行交叉驗證。

表 4: 辨識類在不同模型的平均準確度

模型	靈敏度	特異度	準確度
k-近鄰分類器	84%	90%	88%
隨機森林	89%	92%	91%

可以看到圖 5 的 k-近鄰分類器在預測類與辨識類上有著不小的差距，顯示出 k-近鄰分類器在預測凝凍步態方面表現較為遜色。另一方面，隨機森林模型相比，靈敏度、特異度和準確度平均低了大約 1 到 15 %。此外，隨機森林模型在預測類與辨識類的表現上平分秋色，在預測類的靈敏度甚至達到了 96 %，預測類與辨識類都能達到高達 91 % 的平均準確度，即是正確辨別預測類與辨識類測試資料 91 % 的視窗標籤。如前言

表 5: 預測類在不同模型的平均準確度

模型	靈敏度	特異度	準確度
k-近鄰分類器	75%	87%	83%
隨機森林	96%	88%	91%

所述，隨機森林模型在經過適當的特徵選擇以及分類器的挑選後，在預測以及辨識凝凍步態上都能達到非常優異的效果。

4.3.3 各部位辨識與預測成效

由於受試者的軀幹、大腿以及腳踝三個部位上綁上感測器來收集數據，因此我們想要比較各部位感測器的對於辨識的效果。將從三個部位各自衍生出的部位特徵依相異部位進行三次維度縮減，探討各個部位感測器在分類器的準確度，希望能找出一個較有代表性的部位感測器，使得未來在收集數據時能夠減少穿戴在受試者身上的感測器數量，如此做法不僅減少實驗成本，病患還能更自在的活動且依然能有效辨識凝凍步態。

採用 Relief f 法，針對三個部位維度縮減所得到的特徵，分別進行 10、15、20、25、30 個特徵的維度縮減，利用辨識表現最好的隨機森林模型對辨識類的資料並進行交叉驗證。

表 6: 分部位交叉驗證的平均準確度

特徵個數	腳踝部位特徵	軀幹部位特徵	大腿部位特徵	全部部位特徵
10	86.8%	87.9%	85.5%	89.1%
15	86.7%	87.5%	86.1%	89.1%
20	87.6%	88.1%	86.5%	91%
25	87.6%	88%	87%	90.4%
30	87.6%	87.8%	87.1%	90.7%

軀幹在無論在 10、15、20、25 和 30 個特徵下，模型準確度是三個部位中表現最高的，且經由 ANOVA 檢定，沒有證據顯示三部位的平均準確度是一致的，因此我們接著進行軀幹與其他兩部位的事後檢定，是否有顯著高於其他兩部位平均準確度。此外，單一感測器與三個感測器同時使用的特徵相比，模型平均準確度略低了一些，參照表 6。

當三個部位都選擇前 10 個特徵時，通過敘述性統計可以發現穿戴在軀幹的感測器所得到的準確度是明顯高於穿戴在大腿及腳踝上的感測器的。為了應證這個說法，我們使

表 7: 分部位 ANOVA 事後檢定

特徵個數	同質性檢定	軀幹 vs. 腳踝		軀幹 vs. 大腿	
	p 值	t 值	p 值	t 值	p 值
10	0.919	11.73	< 0.0001	25.14	< 0.0001
15	0.248	8.95	< 0.0001	15.29	< 0.0001
20	0.807	4.61	< 0.0001	16.83	< 0.0001
25	0.828	3.22	0.0018	9.55	< 0.0001
30	0.869	1.3	0.197	25.14	< 0.0001

用變異數分析進行對比。在同質性檢定 (Levene test) 方面，顯著水準為 0.05 時的檢定結果為不拒絕虛無假設，不同組別的樣本觀察值之變異數同質的假設通過。以軀幹做為參考組對其他部位進行比較，可以看到軀幹感測器所得到的準確度顯著高於其他兩個部位感測器，因此在 10 個特徵時穿戴在軀幹上的感測器是最好的。

再者，選擇前 15、20、25 個特徵時，敘述性統計顯示軀幹的準確度仍然高於大腿以及腳踝，同質性檢定的假設也都通過，並且以軀幹做為參考組對其他部位進行比較的結果仍舊顯示穿戴在軀幹的感測器得到的準確度顯著高於其他兩個部位的感測器。

最後，選擇前 30 個特徵時，透過敘述性統計可以發現，腳踝跟軀幹所得到的準確度非常接近。同質性檢定的假設依舊是通過的，但在以軀幹做為參考組對其他部位進行比較的結果來看，可以看到軀幹的準確度仍然是顯著高於大腿，但軀幹跟腳踝的準確度沒有顯著的差別，參照表 7。

若以三個部位來分開比較的話，軀幹所得到的準確度會是最好的，然而，隨著選用特徵數量的增加，腳踝的準確度會逐漸追上軀幹，在選用 30 個特徵時，軀幹跟腳踝的準確度已無顯著差異。由以上分析結果可以得到，當選用小於 30 個的特徵時，軀幹的準確度顯著高於其他兩個部位。因此我們認為軀幹是三個部位中最具有代表性的的感測器，與特徵全用再進行維度縮減相較下，準確度低了 1%，卻還是能有辨識 88% 測試資料標籤，不僅少用兩個感測儀以加速資料蒐集和降低成本、病患不須被多個感測儀干擾測試，還能達到辨識的效果。

4.4 樣條特徵辨識與預測成效

考慮視窗內的樣本點的散布情形，試著配適樣條函數 (Spline)，找出凍凝步態的可能軌跡，分別使用 B 樣條函數 (B Spline, 圖 8) 及三次自然樣條函數 (Natural Cubic Spline, 圖 7)，在兩節點間配適一個三次多項式，取函數之係數作為特徵，利用 Relief F 法降至

20 個特徵數後，代入各分類器模型，執行交叉驗證，並與特徵全用作比較。




圖 7: 三次自然樣條函數




圖 8: B 樣條函數

表 8: 特徵全用的準確率

模型	原始加速度 + 傅立葉轉換		樣條函數	
	平均	標準差	平均	標準差
隨機森林	90%	0.0034	86%	0.0044
k-近鄰演算法	85%	0.0032	78%	0.004

表 9: 維度縮減 20 個特徵的準確率

模型	原始加速度 + 傅立葉轉換		樣條函數	
	平均	標準差	平均	標準差
隨機森林	91%	0.0034	79%	0.0054
k-近鄰演算法	88%	0.0028	75%	0.0043

比較特徵全用 (表 8) 及特徵進行維度縮減的結果 (表 9)，無論是哪個模型，使用全部樣條函數特徵較使用 20 特徵有較高的平均準確度，其最具代表性的前 20 個特徵均為

視窗軌跡曲度變化率 (三次項)，我們認為需要採用所有的樣條的軌跡去配適，即包括常數項、一次項及二次項之係數，較能清楚呈現病患步態的樣貌，以達更高的準確率。

由特徵全用的表現 (表 8) 知兩群特徵間的表現有明顯差距，樣條函數擷取之特徵的平均準確率均較低，變異程度較高，顯示原始加速度所得敘述性統計、經傅立葉轉換之特徵較能準確且穩定地辨別和預測凝凍步態，其餘模型亦得相同結果。我們認為按照視窗樣本點配適樣條函數曲線的確能辨識凝凍步態，且隨機森林模型平均準確度高達 86%，期待透過調整節點數、節點位置或配適不同軌跡方程式以獲得更好的表現。

4.5 留一交叉驗證法探討病人步態一致性

一個良好的模型，面對新進的病患，我們不須收集其步態資料即可有效辨識步態凝凍。為了確認想法的可行性，執行留一交叉驗證 (leave-one-out cross validation)，意旨將每個病患的資料輪流做為測試集，並用其他病患的步態資料訓練分類器，這筆資料中病患 4 和病患 10 因未發生凝凍步態不納入留一交叉驗證中。我們使用 Relief F 法進行維度縮減加速度與傅立葉特徵的 20 個特徵，採用 k-近鄰演算法及隨機森林模型對辨識類的資料進行留一交叉驗證。

表 10: 隨機森林與 k-近鄰演算法辨識類的留一交叉驗證

受試者編號	k-近鄰演算法		隨機森林	
	靈敏度	特異度	靈敏度	特異度
1	23%	92%	20%	98%
2	61%	81%	32%	89%
3	62%	90%	72%	86%
5	24%	91%	49%	89%
6	67%	70%	67%	72%
7	78%	61%	85%	68%
8	4%	98%	13%	94%
9	38%	98%	41%	98%
平均	45%	85%	47%	87%
標準差	0.24	0.12	0.24	0.11

註：病患四與病患十實驗中沒有發生凝凍步態未納入交叉驗證

根據留一交叉驗證得出的結果 (表 10)，我們可以觀察到不論是使用 k-近鄰演算法或隨機森林模型，辨識每個受試者步態資料所得到的敏感度跟特異性都有很大的差異，像

病患三隨機森林模型靈敏度與特異度可以達到七成以上、病患一、病患二和病患八的靈敏度卻不到五成。




圖 9: 隨機森林在 20 個特徵時的留一交叉驗證長條圖

圖 9 說明每個患者的分開測試結果不穩定，進一步認為每個人步態並不一致，導致訓練模型時，因缺乏當事者的步態資料，無法有效的辨識凝凍步態，而解決的方法即是增加受試者數量，取得更多樣的步態資料以解決每個病患步態不一致的問題。

5 結論

在經過各種分析以及嘗試之後，本次研究所得準確率最高的模型是隨機森林以 Relief f 方法縮減至 20 個特徵時在辨識類所達到的靈敏度 89.4 % 以及特異度 91.8% 以及在預測類所達到的靈敏度 96 % 以及特異度 88% 。相比於過往的研究，本次研究首先採用了隨機抽取所有病患資料進而使用 30 折交叉驗證的方法，相比於過往使用單一個病人作為交叉驗證單位的方法能夠獲得更穩定的結果。除此之外，也首次引入了樣條函數來配飾資料並獲取特徵。雖然準確率稍微不及原始加速度以及傅立葉轉換的特徵，但也可以看到辨識類的最高平均準確度達到了 86% ，代表樣條函數來配適是未來值得再更深入研究的方法。同時，本次研究以統計的角度使用樣本獨立性 t 檢定來客觀驗證維度縮減在各個模型上的效用，並且相比於以往的論文更加進行了不同部位的比較，進行統計 ANOVA 分析，成功的使用變異數分析事後檢定來驗證出軀幹在三個部位之中的代表性。

為了驗證理論研究的可行性，並測試這些模型運用到真實生活中的情況，本次研究也將訓練完的模型整合成為一個應用程式，而這個應用程式也成功的在資料蒐集到儀器後，即時的預測以及辨識出了凝凍步態的發生，達到及時與準確的目的，應用程式的實際運作請參照 (實際運作示範)。經由以上一系列的研究與實作，我們認為將這個模型嵌入到穿戴式裝置是可行的，但考量到穿戴式裝置的體積較小且運算能力較差，未來的研究方向勢必需要往輕量型運算的方面進行。

6 附錄

更多詳細資訊請見附錄。

7 參考資料

- [1] Parkinson's Foundation | Better Lives. Together. (<https://www.parkinson.org/>)
- [2] 老年人口成長趨勢 - 人口推估統計查詢系統 (<https://pop-proj.ndc.gov.tw/chart.aspx?c=5uid=4110pid=60>)
- [3] 健保大數據看巴金森 (6-2) ／高齡社會病友年增 2 千人 ([view-source:https://udn.com/news/story/7266/6194101](https://udn.com/news/story/7266/6194101))
- [4] Pardoel, S., Shalin, G., Julie Nantel, Lemaire, E. D., Kofman, J. (2021). Prediction and detection of freezing of gait in Parkinson's disease from plantar pressure data using long short-term memory neural-networks. *Journal of NeuroEngineering and Rehabilitation*, 18(1): e167.
- [5] Pham, T. T., Moore, S. T., Lewis, S. J. G., Nguyen, D. N., Dutkiewicz, E., Fuglevand, A. J., et al. (2017). Freezing of Gait Detection in Parkinson's Disease: A Subject-Independent Detector Using Anomaly Scores. *IEEE Transactions on Biomedical Engineering*, 64(11), 2719-2728.
- [6] Kleanthous, N., Hussaina, A. J., Khana, W., Liatsis, P. (2020). A new machine learning based approach to predict Freezing of Gait. *Pattern Recognition Letters*, 140, 119-126.

- [7] Li, B., Yao, Z., Wang, J., Wang, S., Yang, X., Sun, Y. (2020). Improved Deep Learning Technique to Detect Freezing of Gait in Parkinson's Disease Based on Wearable Sensors. *Electronics*, 9(11): e1919.
- [8] Shalin, G., Pardoel, S., Julie Nantel, Lemaire, E. D., Kofman, J. (2020). Prediction of Freezing of Gait in Parkinson's Disease from Foot Plantar-Pressure Arrays using a Convolutional Neural Network. 2020 42nd Annual International Conference of the IEEE Engineering in Medicine Biology Society (EMBC), 244-247
- [9] UC Irvine Machine Learning Repository.(2013). Daphnet Freezing of Gait Data Set [Data file]. <https://archive.ics.uci.edu/ml/datasets/Daphnet+Freezing+of+Gait>
- [10] Bachlin, M., Plotnik, M., Roggen, D., Maidan, I., Hausdorff, J. M., Giladi, N. and Troster, G., Wearable assistant for Parkinson's disease patients with the freezing of gait symptom, *IEEE Trans Inf Technol Biomed*, Vol. 14, no. 2, 436-46, 2010.
- [11] Mazilu, S., Calatroni, A., Gazit, E. and Roggen, D. Feature Learning for Detection and Prediction of Freezing of Gait in Parkinson's Disease, *Machine Learning and Data Mining in Pattern Recognition Conference*, 2013. DOI:10.1007/978-3-642-39712-7_11
- [12] J. D. Schaafsma, Y. Balash, T. Gurevich, A. L. Bartels, J. M. Hausdorff, and N. Giladi, "Characterization of freezing of gait subtypes and the response of each to levodopa in parkinson's disease," *European Journal of Neurology*, vol. 10, no. 4, pp. 391—398, 2003.

專題競賽報告分工表

學號	姓名	分工內容
410878043	嚴潔翎	樣條函數研究、降維方法研究、模型研究、書面報告協作
410878049	柯怡瑄	PPT 製作、app 介面設計、降維方法研究、模型研究、書面報告協作
410878021	黃承平	資料處理、模型研究
410878045	賴仁凱	模型研究、模型結果繪製、書面報告協作
410878008	許弘叡	模型研究、app 製作、分部位研究、書面報告協作、口頭報告
410878048	葉于廷	樣條函數研究、降維方法研究、模型研究、書面報告製作、口頭報告、動機與背景研究