

運用統計模型與分類器分辨帕金森氏患者 產生步態凝凍與步態凝凍前的狀態

嚴潔翎、柯怡瑄、黃承平、賴仁凱、許弘叡、葉于廷

國立臺北大學統計學系

May 28, 2022

摘要

晚期帕金森氏患者會頻繁出現凝凍步態，高度的影響病患的行走能力，甚至導致跌倒與受傷，目前對於此症狀採取人工辨識且沒有藥物能完全治療凝凍步態，如果能預測凝凍步態並提示將要發作的患者將能大幅提升他們的生活品質與改善行動能力。

這份資料有帕金森氏患者在三個部位(大腿，軀幹，腳踝)穿戴加速度感測儀資料，透過特徵擷取總共有 508 個特徵，並從最小冗餘最大特徵法 (mRMR)、Relief f 和互資訊 (mutual information) 中，找出最佳的維度縮減方法，找出較能辨識凝凍步態的資料，接著，從支援向量機 (SVM)、羅吉斯迴歸 (Logistic Regression)、隨機森林 (Random Forest)、k-近鄰分類器 (KNN)、單純貝氏 (Naive Bayes) 和 RUSBoost 挑選出合適的分類器來辨識與預測凝凍步態。

定義辨識是從凝凍步態發生前兩秒開始到發生結束，而預測是從凝凍步態發生前兩秒到剛要發生時。對於凝凍步態的辨識與預測，表現最好是隨機森林的模型，辨識凝凍步態整個過程可達靈敏度 89% 和特異度 92%、從前兩秒開始預測的凝凍步態也可達到靈敏度 96% 和特異度 88%。另一方面，在患者只穿戴軀幹的感測儀時，辨識凝凍步態可達到 88% 的準確度。此外，本次研究以統計的角度，針對資料的特性配適樣條函數特徵，並使用統計方法審視各個部位對於辨識凝凍步態的貢獻，與評估使用維度縮減的合理性，最後得出最有效的辨識凝凍步態的模型，甚至在減少穿戴的感測儀下還能近乎九成辨識凝凍步態，研究中分類器優異表現在引入提示聲後能改善帕金森氏症患者的日常活動以及給予生活自主的能力。

1 前言

帕金森氏症是繼阿茲海默症後，全球第二常見的神經退化疾病，會伴隨身體僵硬與失眠的情況，據 Parkinson's Foundation 統計，全世界有超過 1000 萬人罹患帕金森氏症，且患病人數因人口老化日益增長。已知帕金森氏症的發病率會隨著年齡的增長而增加，60 歲以上每增加一歲，盛行率便提高 1 %；80 歲以上則每增加一歲，盛行率上升 4%。在臺灣，據內政部統計，民國 110 年我國老年人口 (65 歲以上) 393.9 萬人，相較前一年增加約 15.1 萬人，上升 4 %，隨著老年人口基數增加，罹病患者會日益增多，其中目前健保統計因帕金森氏症就醫的患者共 77428 人，約占老年人口的 2 %，相當於在一百位六十五歲以上的年長者中，平均有兩位是帕金森氏症患者。嚴重的是，到了病症的晚期，病患會開始有行走與溝通的困難，甚至開始有容易感到疲倦、憂鬱等心理問題，需要長照的他們日漸為社會帶來龐大的社會成本。隨著病患占世界人口比例的漸增，間接加重了生產者的經濟與勞力負擔，影響的雙方的生活品質。

凝凍步態是帕金森氏症的病徵，此症狀發作時，病患雙腿無法向前邁步，待在原地顫抖，在回復到正常狀態前，病患急需他人攙扶或支撐以保持平衡。此症狀很容易在患者身處人群時發生。例如上下火車時，人群在車門附近迅速地聚集會使病患情緒不穩，間接影響病徵的出現，此刻病患突然無法行動是非常危險的，推擠與催促使病患更加緊張，愈無法緩解病徵，大幅增加受傷的機會。現今對於凝凍步態發作尚未有一個明確的定義，目前是依人工觀察來判斷症狀是否發生，但這並非是長遠之計，長期觀察一個人症狀發生時的特徵並時刻注意他的安危，不僅消耗社會資源，也容易造成患者的心理負擔。此研究的目的是期望能讓帕金森氏症的患者能夠盡可能擁有自主生活的能力。

隨著資料收集技術與機器學習理論的成熟，已經可以將凝凍步態問題導入人工智慧中，透過攜帶式裝置收集病人的步態資料，並加以訓練人工智慧，能獲取比主觀判別更優秀的辨別標準且更準確地偵測步態的異常，甚至可在凝凍步態發生前發現到步態的異常。未來將裝置導入實際生活獲取大量步態資料後即能完整的訓練模型，得到更精確的判斷，並在發生病症時，發出提示聲提醒病患與周遭的人，除了病患能夠知道本身正在發作凝凍步態，他人也能較易觀察異樣在旁提供協助，使病患免於跌倒受傷的風險，擁有更完善的生活品質，同時減輕醫療照護負擔，舒緩社會壓力。

2 文獻回顧

早在我們之前，已有很多人研究過使用非人工的方法辨識、預測凝凍步態，其中不乏各種機器學習的方法。Pardoel, S., Shalin, G., Julie Nantel, Lemaire, E. D., Kofman, J. (2021)

使用足底壓力、腳踝與大腿三軸加速度和角速度資料，配合決策樹 (decision tree) 和隨機下取樣演算法 (RUSBoost)，對前凝凍步態與凝凍步態的偵測達到 85% 靈敏度和 94% 特異度。[6] Pham, T. T., Moore, S. T., Lewis, S. J. G., Nguyen, D. N., Dutkiewicz, E., Fuglevand, A. J., et al. (2017) 使用腳踝、大腿與軀幹的三軸加速度和他們的異常檢測演算法對凝凍步態與非凝凍步態做分類，得到 87.5 % 的靈敏度，84.5 % 的特異度。[7] Kleanthous, N., Hussaina, A. J., Khana, W., Liatsis, P. (2020) 使用腳踝、大腿、軀幹的三軸加速度，配合支援向量機 (SVM)，對凝凍步態、凝凍步態過渡期和無凝凍步態進行三種分類，分別達到 72%，91%，75% 的靈敏度和 87%，88%，93% 的特異度。[8] Li, B., Yao, Z., Wang, J., Wang, S., Yang, X., Sun, Y. (2020) 同樣使用腳踝、大腿、軀幹的三軸加速度，並使用深度卷積神經網路和長短期記憶模型分辨凝凍步態和非凝凍步態，達到 95% 靈敏度和 98% 特異度。[1] Shalin, G., Pardoel, S., Julie Nantel, Lemaire, E. D., Kofman, J. (2020) 將足底壓力資料輸入卷積神經網路，對凝凍步態、前凝凍步態和無凝凍步態進行三種分類，分別達到 92%，94%，92% 靈敏度，96%，95%，98% 特異度。[2] 在種種文獻中，儘管有部分研究使用相同資料集，但隨標籤的定義、使用的特徵和分類器的異同，辨識凝凍步態的成效也大相逕庭。

3 研究方法及步驟

3.1 資料來源

實驗資料是來自於加利福尼亞大學爾灣分校 (University of California-Irvine) 所建構的 UCI 資料庫系統中心。這個實驗為帕金森氏症患者的行走實驗，實驗室中會記錄病人的步態資料，分別要求好發凝凍步態的受試者在各個部位穿戴內建微型電腦的加速度感測儀（綁在腳踝、大腿以及臀部）後，沿著研究路徑進行十分鐘實驗，其中動作包括隨意走動、轉彎和停止，並記錄 x、y 和 z 方向的加速度。過程中，凝凍步態的辨別是依照身旁物理治療師的觀察。在實驗過程中，加速度感測器會以 64 Hz 的頻率紀錄資料。資料分類分成三類，分別為不屬於實驗範圍的動作 (資料中以 0 來表示)、沒有發生凝凍步態 (資料中以 1 來表示) 和發生凝凍步態 (資料中以 2 來表示)。

3.2 資料處理

3.2.1 資料平衡

由於原始資料中具有大量的標記為不屬於實驗範圍的動作，若將原始資料配飾到模型中，分類器會傾向猜測不屬於實驗範圍的動作，使得模型會過度配適。除此之外，因為在最初與最後的幾筆資料是接近實驗開始跟結束時，此時的資料大部分都是實驗外的動作，我們認為這些資料不應被納入模型中，因此選擇將資料去頭去尾。去頭的定義為：從頭開始算，直到遇到第一筆實驗內的動作的資料時，在該筆前面的實驗外動作的資料全部移除、而去尾的定義為：從最後一筆資料開始往前計算，直到遇到第一筆實驗內的動作的資料時，在該筆資料後面的資料全部移除。

3.2.2 視窗切割

收集完的資料為單一時點的加速度資料，而為了觀察出較完整的行動軌跡，我們將多個資料點整併為一個視窗，視為一個樣本，並採用滑動視窗法 (Sliding Window)。在 Marc Bachlin 論文中，將資料的視窗定義成 4 秒一個視窗，且兩個相鄰視窗間的重疊時間為 3.5 秒，即視窗一次滑動 0.5 秒。為了增加樣本數，我們縮短每個視窗的時間，將視窗持續時間定義為 1 秒一個視窗，且兩個相鄰視窗的重疊時間調整為 0.75 秒，即一次滑動時間為 0.25 秒。

3.2.3 視窗定義

參考 Pardoel [1] 的研究，視窗分為四種狀態：無凝凍步態 (No-FOG)、凝凍步態前 (Pre-FOG)、凝凍步態過渡期 (Pre-FOG Transition)、凝凍步態 (FOG)，在廣義的分類中，後三種都屬凝凍步態。凝凍步態事件的前兩秒稱做前凝凍步態片段 (Pre-FOG segment)，發生期間稱做凝凍步態片段 (FOG segment)，其他期間稱之為無凝凍視窗片段 (No-FOG segment)。完整視窗落前凝凍步態片段中在被定義為前凝凍步態 (Pre-FOG)，像圖 1 中的 W 7 - W 11，若視窗的開頭落在前凝凍步態片段，結束落在凝凍步態片段中，則視窗被分類為凝凍步態過渡期 (Pre-FOG transition)，像圖 1 中的 W 12 - W 16，視窗完整落在凝凍步態片段中則被分類為凝凍步態 (FOG)，像圖 1 中的 W 17，其餘的視窗則被分類為無凝凍步態 (No-FOG)。




圖 1: 視窗定義示意圖 (摘錄自 [6])

	目標類別	非目標類別
辨別類	前凝凍步態 + 凝凍步態過渡期 + 凝凍步態	無凝凍步態
預測類	前凝凍步態 + 凝凍步態過渡期	無凝凍步態

表 1: 判斷與預測凝凍步態類別之分類

3.2.4 目標和非目標類定義

為了較簡易的評估預測與辨別的成效，我們將四類的視窗再進一步定義為兩類 (目標類別與非目標類別)。辨別類的目標類別蒐集所有關於凝凍步態的訊息，即前凝凍步態、凝凍步態過渡期和凝凍步態，並將無凝凍步態定為非目標類，而預測類的目標類別納入凝凍步態發生前的徵兆為前凝凍步態和凝凍步態過渡期，並視無凝凍步態定為非目標類，參照表 1。

3.3 特徵擷取

根據 [7], [8], [2] 與樣條函數所產生特徵，視窗的特徵值可大致分為三種。第一種，原始加速度得到的敘述性統計，如表 2。另外，因為三個部位各有三軸，所以以下特徵值除了平均加速度能量 (AAE) 外都是衍伸出 9 個特徵值，而平均加速度能量 (AAE) 則為 3 個特徵值。第二種，原始資料經傅立葉轉換後得到的數值，如表 3，故總共有 129 個根據文獻所得特徵值。第三種，有別於其他論文，利用樣條函數配適加速度資料點，估計出合適的軌跡，取出 B-樣條 (B-spline) 基底的座標為特徵和自然三次樣條的每段的方程式係數作為特徵，如表 4，共有 396 個特徵。以下為特徵定義：

特徵名稱	描述
最大值 最小值 平均值 標準差 中位數	原始加速度數所得敘述性統計
主導方向的特徵值 (eigenvalues) (EVA)	加速度沿三軸共變異數矩陣的特徵值

表 2: 原始加速度值所得特徵

特徵名稱	描述
最大值 最小值 平均值	原始加速度值經過傅立葉轉換後所得能量在各個視窗的敘述性統計
平均加速度能量 最大頻率 凝凍帶 運動帶 凝凍指數 總能量	三軸能量的平均 (AAE) 最大能量值所對應的頻率 3 —8 Hz 間的能量加總 (Freezing band) 0.5 —3 Hz 間的能量加總 (Locomotor band) 3 —8 Hz 除以 0.5 —3 Hz 間的能量加總 (Freezing Index) 視窗內能量的加總 (Totalpower)

表 3: 經過傅立葉轉換後所得特徵

特徵名稱	描述
三次自然樣條一階係數 三次自然樣條二階係數 三次自然樣條三階係數 三次自然樣條四階係數	三次自然樣條估計加速度數值方程式各次項係數
B-樣條基底座標元素	估計加速度數值得到的基底座標元素

表 4: 樣條函數估計視窗特徵

3.4 維度縮減

1. Relief f

是從維度縮減的 Relief 法延伸出的改良方法，相較於 Relief 法，能處理多類別問

題，適用於各種型態的資料。其步驟是先給定所有變數的初始權重，透過不斷遞迴計算，最後挑選出權重較高的前幾名變數作為較為重要的代表。其遞迴過程是選定一個隨機樣本，計算與其同類和異類的曼哈頓距離，同類的距離越小代表越像此類則增加同類樣本權重，異類的距離越大則減少異類樣本權重，能較 Relief 法減少雜訊干擾，得到更穩健的結果。

2. 互資訊 (Mutual Information, MI)

度量了兩個變數之間相互依賴的程度。對於兩個隨機變數，MI 是在獲得一個隨機變數的資訊之後，觀察另一個隨機變數所獲得的「資訊量」。相互資訊的概念與隨機變數的熵緊密相關。互資訊愈大代表所降低的不確定性愈多，則關聯性愈強。互資訊不僅度量實值隨機變數和線性相關性 (如相關係數)，更可捕捉兩變數間任何形式的相依程度。

3. 最小冗餘最大特徵法 (minimum-redundancy maximum-relevance, mRMR)

以迭代方式工作，每次迭代都會透過計算分數來選出最佳特徵，被選入特徵集後就不再被挑出，而特徵的選擇與結果有高度相關，且特徵集內的特徵之間相關性最小，以降低冗餘性。類別型可利用互資訊 (MI) 計算，連續型可利用互資訊或 F 檢定及 Pearson 相關係數計算。此演算法只適用於監督式學習，且計算快速。

3.5 模型開發

3.5.1 分類器模型介紹

1. 支援向量機 (SVM)

是一種監督式學習，透過將資料點映在高維空間中並建構超平面，以進行分類、迴歸或其他任務。給定一組訓練集，每個資料點會被標記為屬於兩個類別中的其中一類，支援向量機假設存在一個超平面 $\vec{w}^T \vec{x} + \vec{b} = 0$ 可以完美分割兩組資料，透過計算 \vec{w} 及 \vec{b} 使得兩類之間的邊界最大化，並將資料重新分類為兩個類別之一。值得注意的是，需要先對資料的每個特徵進行標準化，使資料點的每個特徵在支援向量機裡同等重要。

2. 隨機森林 (Random forest)

屬於集成學習 (Ensemble learning) 法。訓練分類器時，建造多個分類樹 (Decision Tree)，再以拔靴法 (Bootstrap) 抽樣進行訓練，最後採多數決決定分類結果。樹的分支則是利用熵 (Entropy) 或吉尼不純度 (Gini impurity)，尋找特徵子集內擁有最

大資訊增益 (Information Gain, IG) 的變數，進而停止分割節點。與單一分類樹相比，此方法較能降低偏誤及變異，且不易過度擬和。

3. RUSboost

全名為 Random Under Sampling，用於解決不平衡資料的分類器，RUSboost 結合資料抽樣和集成模型的方法。其步驟為：先給定所有變數的初始權重，透過不斷遞迴計算，更新每個變數的權重，其中每次計算會隨機抽取一定數量的多數類樣本，和所有的少數類組成訓練數據集，接著利用決策樹分類，計算出錯誤率，針對錯誤最多的類別改變權重計算方式，在固定迴圈或收斂下，決定目前為止最佳的分類器作為分類結果。

4. 單純貝氏 (Naive bayes)

為一種構建分類器的方法。它不是訓練這種分類器的單一演算法，而是一系列基於相同原理的演算法：所有單純貝氏分類器都假定樣本特徵間彼此獨立。在許多實際應用中，單純貝氏模型參數估計使用最大概似估計方法，換言之，在不用到貝氏機率或者任何貝氏模型的情況下，單純貝氏模型也能奏效。儘管假設很簡單，但單純貝氏分類器在很多複雜的現實情形中仍能夠取得相當好的效果。優勢在於只需根據少量的訓練資料，即能估計出必要的參數（變數的均值和變異數），且由於變數獨立假設，所以不需要確定整個共變異數矩陣。

5. K-近鄰演算法 (KNN)

又稱 KNN 演算法，屬監督式學習。訓練資料為具有標籤的資料，計算每個樣本點與目標點之歐式距離，選 k 個最近點並做類別判斷。判別方式分為兩種：投票法及加權投票法，分類結果為類別最多的組別，兩者差別為後者考慮近鄰之距離遠近進行加權，再進行分類。優點是精度高且無資料輸入假定、資料型態不受限，缺點是時間空間複雜度高，樣本平衡度依賴高。

6. 羅吉斯回歸 (Logistic Regression)

主要在探討依變數與自變數之間的關係，與一般線性回歸不同處在：依變數為類別變數，特別是分成兩類的變數。利用自變數的線性組合與連結函數預測發生步態凝凍的機率，透過連結函數將線性組合轉換為分布在 0 到 1 之間之機率值，若機率大於門檻值則判定會發生步態凝凍。優點是方便計算與訓練，且自變數不需常態分佈的假設，故限制較少。

3.5.2 評估指標

綜合模型的表現可分成下列四個部分：真陽性 (True Positive, TP) 代表為該視窗實際為凝凍步態且預測該視窗亦為凝凍步態；真陰性 (True Negative, TN) 代表為該視窗實際為非凝凍步態且預測該視窗亦為非凝凍步態；偽陰性 (False Negative, FN) 代表該視窗實際為凝凍步態且預測該視窗為非凝凍步態；偽陽性 (False Positive, FP) 該視窗實際為非凝凍步態且預測該視窗為凝凍步態，並依此建構各項評估指標，評估分類器的表現之優劣。各項評估指標陳列於表 5，靈敏度 (Sensitivity) 評估的是真實狀態為陽性其預測結果亦為陽性的比率、特異度 (Specificity) 評估的是真實狀態為陰性其預測結果亦為陰性的比率，準確率 (Accuracy) 測量分類正確占整體的比率。

真實狀態	預測結果	
	正類	負類
正類	TP	FN
負類	FP	TN

表 5: 預測結果分類

評估指標	定義
靈敏度 (Sensitivity)	$TP/(FN+TP)$
特異度 (Specificity)	$TN/(FP+TN)$
準確率 (Accuracy)	$(TP+TN)/(TP+FP+TN+FN)$

表 6: 評估指標

4 研究結果

4.1 資料狀況

評估這份資料是否符合合適的收集，我們將每位病患的凝凍步態持續時間記錄下來，並繪製直方圖 (圖 2)，50 % 病患發生凝凍步態的時間是小於 5.4 秒的，根據 J. D. Schaafsma 研究 [5]，此分布是類似病患早期凝凍步態的狀況，因此我們認定這資料的搜集是成功的。

以四個類別定義視窗，可以切割為 112023 個無凝凍步態視窗、6000 個前凝凍步態視窗、906 個凝凍步態過渡期視窗和 878 個無凝凍步態視窗，參照表 7。此外，病患 10 和

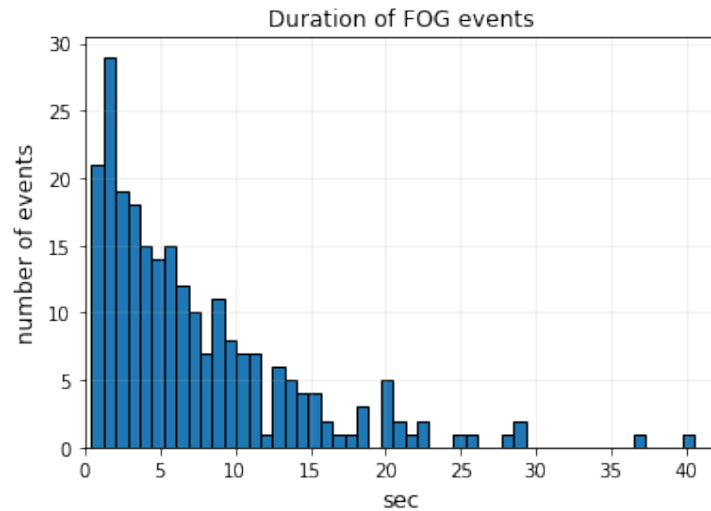


圖 2: 十位病患凍凝步態持續時間直方圖

病患代碼	無凝凍步態	凝凍步態	凝凍步態過渡期	前凝凍步態
01	12248 (96.1%)	332 (2.6%)	80 (0.6%)	88 (0.7%)
02	9323 (92.02%)	632 (6.2%)	92 (0.9%)	84 (0.8%)
03	14492 (91.6%)	956 (6%)	198 (1.3%)	170 (1.1%)
04	12230 (100%)			
05	11013 (83.7%)	1640 (12.5%)	256 (1.9%)	248 (1.9%)
06	13171 (95.9%)	488 (3.6%)	39 (0.3%)	41 (0.3%)
07	10205 (96.2%)	228 (2.1%)	87 (0.8%)	89 (0.8%)
08	7672 (89.9%)	749 (8.8%)	54 (0.6%)	58 (0.7%)
09	9591 (89.1%)	975 (9.1%)	100 (0.9%)	100 (0.9%)
10	12078 (100%)			
全部病患	112023 (94%)	6000 (5%)	906 (1%)	878 (1%)

表 7: 十位病患凝凍步態分類頻率表

病患 4 的視窗只能分類成無凝凍步態，意味著兩位受試者在實驗當下沒有發生凍凝步態。另一方面，每人凍凝步態視窗數量會因凍凝步態發生次數的不一而差異很大，像是病患 7 只有 228 個凍凝步態視窗，而病患 5 則是病患 7 的近 7 倍，共有 1640 個凍凝步態視窗。

視窗分為四類後，我們進一步分類成兩類，較易觀察模型的結果，而辨識類與預測類的目標視窗數與非目標視窗卻有極大的差異。

辨識類：

1. 目標類 (前凝凍步態、凝凍步態過渡期和凝凍步態) 共 7784 (6000 + 906 + 878) 個

視窗。

2. 非目標類 (無凝凍步態) 共 112023 個視窗。

預測類:

1. 目標類 (前凝凍步態、凝凍步態過渡期) 共 1784 (906 + 878) 個視窗。
2. 非目標類 (無凝凍步態) 共 112023 個視窗。

4.2 交叉驗證法 (Cross validation)

檢視分類器是否穩定的預測與辨識凍凝步態，進而引入交叉驗證法。因凍凝步態 (目標類) 與非凍凝步態 (非目標類) 筆數懸殊，目標類占不到全部視窗 20%，避免分類器產生偏誤，故先將資料平衡，取所有目標類視窗，再抽取目標類視窗數兩倍的非目標視窗。將目標類與非目標類各採 70% 合併為訓練集，測試集則為剩餘的各 30% 合併，整理成較為平衡的資料集，參考圖 3。重複 30 次抽取非目標視窗，又因非目標類視窗遠超過目標類視窗，故每次抽取之視窗不一定相同，讓非目標類視窗之特徵能較完整的被訓練，共產生 30 個訓練集及 30 個測試集。




圖 3: 交叉驗證示意圖

4.3 原始加速度特徵與傅立葉變數特徵

我們蒐集以往論文中的特徵，藉以評估哪些較有可能是凝凍步態跡象的可能。主要分為兩大類分別是傅立葉特徵 (表 3) 和加速度特徵 (表 2)。

4.3.1 合適的維度縮減方法與模型

維度縮減是從多個特徵中，找出其中較有代表性的特徵，不僅能加速模型的運算且不失辨識能力，也能說明哪些是利於辨識凝凍步態的關鍵資料。為此，我們將這些特徵進行維度縮減後，對辨識類的資料進行交叉驗證，分別討論每個模型配適辨識類的資料情形。

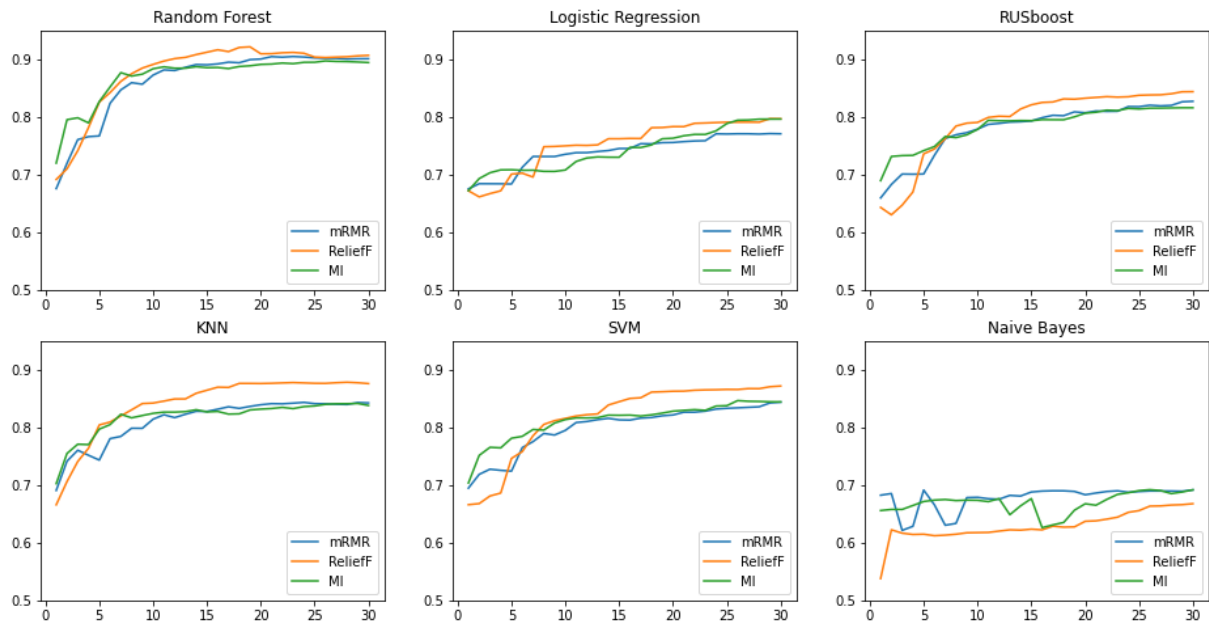


圖 4: 三種維度縮減在不同維度縮減數量各模型的平均準確度

維度縮減從一個到三十個特徵，固定維度縮減方法與數量下，進行辨識類資料的交叉驗證，再將 30 次測試的結果的準確度平均，而繪製出圖 4 上的其中一點的結果，而不同條線代表的是另一種維度縮減方法。

一般的分類器會在特徵愈多時，表現會越好，即，交叉驗證所得的 30 個準確度較高。在圖 4，可印證此想法，一開始交叉驗證在特徵小於二十時，平均準確度雖有小動盪但有愈來愈高的趨勢，而隨著特徵數目從 20 增加時，六個分類器平均準確度呈現緩慢上升的趨勢，因此我們認為 20 是維度縮減適合的特徵數量，進而比較模型之間的表現情況。此外，三個維度縮減方法中，除了 Naive Bayes 模型，另外五個模型在使用 Relief f 挑出 20 以上特徵的平均準確度會高於使用最小冗餘最大特徵法 (mRMR) 以及互

資訊 (mutual information) 的平均準確度，因此我們選用 Relief f 最為此次研究的維度縮減方法。

對資料進行檢視後，我們認為這筆資料特徵違反了 Naive Bayes 的假設並沒有符合常態分布，也因此平均準確度大幅遠低於其他模型，所以我們先不考慮使用此模型，接著，討論剩下五個的模型維度縮減的合理性，分別是羅吉斯回歸、隨機森林、KNN、RUSboost SVM，用所有特徵與 20 個特徵全用的交叉驗證平均準確度進行獨立樣本 t 檢定，檢視是否維度縮減前後是否有顯著差異的平均準確度。




圖 5: 相異模型維度縮減前後的準確度盒型圖

最後，最高的平均準確度是在維度縮減至 20 特徵的隨機森林模型，大約 91 %，呈現出此資料可以因維度縮減能有更好的分類模型 (圖 5)。此外，KNN 與隨機森林模型在 Relief f 20 個特徵時，交叉驗證的平均準確度會顯著高於使用全部特徵進行訓練，而羅吉斯回歸、RUSboost、SVM 則得到顯著低於的結果，代表如要進行維度縮減，使用 KNN 與隨機森林模型較為合適，不但計算加速且比特徵全用有更好的表現，也找到了較具有代表性的 20 個特徵，分別為原加速度的中位數、最大值和最小值以及傅立葉分析加速度的最大頻率。

4.3.2 交叉驗證的預測與辨識凝凍步態成效

除了訓練出來的模型除了可以完整的辨識整個凝凍步態的過程，我們也希望可以在凝凍步態發生前就能成功預測，因此將辨識類為辨識凝凍步態發生的整個過程移去疾病當下的資料，而成目標類只有前凝凍步態以及凝凍步態過渡期視窗的預測類，參照表 1。以下分別採用預測類及辨識類的資料集以及維度縮減 Relief f 取前 20 個特徵進行交叉驗證。

模型	靈敏度	特異度	準確度
k-近鄰分類器	84%	90%	88%
隨機森林	89%	92%	91%

表 8: 辨識類在不同模型的平均準確度

模型	靈敏度	特異度	準確度
k-近鄰分類器	75%	87%	83%
隨機森林	96%	88%	91%

表 9: 預測類在不同模型的平均準確度

可以看到 KNN 在預測類與辨識類上有著不小的差距，顯示出 KNN 在預測凝凍步態方面表現較為遜色。另一方面，隨機森林模型相比，靈敏度、特異度和準確度平均低的大約 1 到 15 %。此外，隨機森林模型在預測類與辨識類的表現上平分秋色，在預測類的靈敏度甚至達到了 96 %，預測類與辨識類都能達到高達 91 % 的平均準確度，即是正確辨別預測類與辨識類測試資料 91 % 的視窗標籤。如前言所述，隨機森林模型在經過適當的特徵選擇以及分類器的挑選後，在預測以及辨識凝凍步態上都能達到非常優異的效果。

4.3.3 各部位辨識與預測成效

由於受試者的軀幹、大腿以及腳踝三個部位上綁上感測器來收集數據，因此我們想要比較各部位感測器的對於辨識的效果。將從三個部位各自衍生出的部位特徵依相異部位進行三次維度縮減，探討各個部位感測器在分類器的準確度，是否能找出一個較有代表性的部位感測器，使得未來在收集數據時能夠減少穿戴在受試者身上的感測器數量，使病患能更自在的活動且依然能有效辨識凝凍步態。

我們採用 Relief F 法針對三個部位維度縮減所得到的特徵，分別進行 10、15、20、25、30 個特徵的維度縮減，利用辨識表現最好的隨機森林模型對辨識類的資料並進行交叉驗證。

特徵個數	腳踝部位特徵	軀幹部位特徵	大腿部位特徵	全部部位特徵
10	86.8%	87.9%	85.5%	89.1%
15	86.7%	87.5%	86.1%	89.1%
20	87.6%	88.1%	86.5%	91%
25	87.6%	88%	87%	90.4%
30	87.6%	87.8%	87.1%	90.7%

表 10: 分部位交叉驗證的平均準確度

軀幹在無論在 10、15、20、25 和 30 個特徵下，模型準確度是三個部位中表現最高的，且經由 ANOVA 檢定，沒有證據顯示三部位的平均準確度是一致的，因此我們接著進行軀幹與其他兩部位的事後檢定，是否有顯著高於其他兩部位平均準確度。此外，單一感測器與三個感測器同時使用的特徵相比，模型平均準確度略低了一些，參照表 10。

特徵個數	同質性檢定	軀幹 vs. 腳踝		軀幹 vs. 大腿	
	p 值	t 值	p 值	t 值	p 值
10	0.919	11.73	< 0.0001	25.14	< 0.0001
15	0.248	8.95	< 0.0001	15.29	< 0.0001
20	0.807	4.61	< 0.0001	16.83	< 0.0001
25	0.828	3.22	0.0018	9.55	< 0.0001
30	0.869	1.3	0.197	25.14	< 0.0001

表 11: 分部位 ANOVA 事後檢定

當三個部位都選擇前 10 個特徵時，通過敘述性統計可以發現穿戴在軀幹的感測器所得到的準確度是明顯高於穿戴在大腿及腳踝上的感測器的。為了應證這個說法，我們使用變異數分析進行對比。在同質性檢定 (Levene test) 方面，顯著水準為 0.05 時的檢定結果為不拒絕虛無假設，不同組別的樣本觀察值之變異數同質的假設通過。以軀幹做為參考組對其他部位進行比較，可以看到軀幹感測器所得到的準確度顯著高於其他兩個部位感測器，因此在 10 個特徵時穿戴在軀幹上的感測器是最好的。

再來，選擇前 15、20、25 個特徵時，敘述性統計顯示軀幹的準確度仍然高於大腿以及腳踝，同質性檢定的假設也都通過，並且以軀幹做為參考組對其他部位進行比較的結果仍舊顯示穿戴在軀幹的感測器得到的準確度顯著高於其他兩個部位的感測器。

最後，選擇前 30 個特徵時，透過敘述性統計可以發現，腳踝跟軀幹所得到的準確度非常接近。同質性檢定的假設依舊是通過的，但在以軀幹做為參考組對其他部位進行比較的結果來看，可以看到軀幹的準確度仍然是顯著高於大腿，但軀幹跟腳踝的準確度沒有顯著的差別，參照表 11。

可以發現，若以三個部位來分開比較的話，軀幹所得到的準確度會是最好的。然而，隨著選用特徵數量的增加，腳踝的準確度會逐漸追上軀幹，在選用 30 個特徵時，軀幹跟腳踝的準確度已無顯著差異。由以上分析結果可以得到，當選用小於 30 個的特徵時，軀幹的準確度顯著高於其他兩個部位。因此我們認為軀幹是三個部位中最具有代表性的的感測器，與特徵全用再進行維度縮減相較下，準確度低了 1%，卻還是能有辨識 88% 測試資料標籤，不僅少用兩個感測 18 儀加速資料蒐集和降低成本、病患不須被多個感測儀干擾測試，還能不失辨識的效果。

4.4 樣條特徵辨識與預測成效

考慮視窗內的樣本點的散布情形，試著配適樣條函數 (Spline)，找出凍凝步態的可能軌跡，分別使用 B 樣條函數 (B Spline, 圖 7) 及三次自然樣條函數 (Natural Cubic Spline, 圖 6)，在兩節點間配適一個三次多項式，取函數之係數作為特徵，利用 Relief F 法降至 20 個特徵數後，代入各分類器模型，執行交叉驗證，並與特徵全用作比較。




圖 6: 三次自然樣條函數

模型	原始加速度 + 傅立葉轉換		樣條函數	
	平均	標準差	平均	標準差
隨機森林	90%	0.0034	86%	0.0044
k-近鄰演算法	85%	0.0032	78%	0.004

表 12: 特徵全用的準確率




圖 7: B 樣條函數

模型	原始加速度 + 傅立葉轉換		樣條函數	
	平均	標準差	平均	標準差
隨機森林	91%	0.0034	79%	0.0054
k-近鄰演算法	88%	0.0028	75%	0.0043

表 13: 維度縮減 20 個特徵的準確率

比較特徵全用 (表 12) 及特徵進行維度縮減的結果 (表 13)，無論是哪個模型，使用全部樣條函數特徵較使用 20 特徵有較高的平均準確度，其最具代表性的前 20 個特徵均為視窗軌跡曲度變化率 (三次項)，我們認為需要採用所有的樣條的軌跡去配適，即包括常數項、一次項及二次項之係數，較能清楚呈現病患步態的樣貌，以達更高的準確率。

由特徵全用的表現 (表 12) 知兩群特徵間的表現有明顯差距，樣條函數擷取之特徵的平均準確率均較低，變異程度較高，顯示原始加速度所得敘述性統計、經傅立葉轉換之特徵較能準確且穩定地辨別和預測凝凍步態，其餘模型亦得相同結果，參考附錄 ??。我們認為按照視窗樣本點配適樣條函數曲線的確能辨識凝凍步態，且隨機森林模型平均準確度高達 86%，期待透過調整節點數、節點位置或配適不同軌跡方程式以獲得更好的表現。

4.5 留一交叉驗證法探討病人步態一致性

一個良好的模型，面對新進的病患，我們不須收集其步態資料即可有效辨識步態凝凍。為了確認想法的可行性，執行留一交叉驗證 (leave-one-out cross validation)，意旨將每個病患的資料輪流做為測試集，並用其他病患的步態資料訓練分類器，這筆資料中病患 4 和病患 10 因未發生凝凍步態不納入留一交叉驗證中。我們使用 Relief F 法進行維度縮減加速度與傅立葉特徵的 20 個特徵，採用 k-近鄰演算法及隨機森林模型對辨識類的資料進行留一交叉驗證。

受試者編號	k-近鄰演算法		隨機森林	
	敏感度	特異度	敏感度	特異度
1	23%	92%	20%	98%
2	61%	81%	32%	89%
3	62%	90%	72%	86%
5	24%	91%	49%	89%
6	67%	70%	67%	72%
7	78%	61%	85%	68%
8	4%	98%	13%	94%
9	38%	98%	41%	98%
平均	45%	85%	47%	87%
標準差	0.24	0.12	0.24	0.11

註：病患四與病患十實驗中沒有發生凝凍步態未納入交叉驗證

表 14: 隨機森林與 k-近鄰演算法辨識類的留一交叉驗證

根據留一交叉驗證得出的結果 (表 14)，我們可以觀察到不論是使用 k-近鄰演算法或是隨機森林模型，辨識每個受試者步態資料所得到的敏感度跟特異性都有很大的差異，像病患三隨機森林模型靈敏度與特異度可以達到七成以上、病患一、病患二和病患八的靈敏度卻不到五成。




圖 8: 隨機森林在 20 個特徵時的留一交叉驗證長條圖

圖 8，說明每個患者的分開測試結果不穩定，進一步認為每個人步態並不一致，導

致訓練模型時，因缺乏當事者的步態資料，無法有效的辨識凝凍步態，而解決的方法即是增加受試者數量，取得更多樣的步態資料以解決每個病患步態不一致的問題。

5 結論

在經過各種分析以及嘗試之後，本次研究所得準確率最高的模型是隨機森林以 **Relieff** 方法縮減至 20 個特徵時在辨識類所達到的靈敏度 89.4 % 以及特異度 91.8% 以及在預測類所達到的靈敏度 96 % 以及特異度 88% 。相比於過往的研究，本次研究首先採用了隨機抽取所有病患資料進而使用 30 折交叉驗證的方法，相比於過往使用單一個病人作為交叉驗證單位的方法能夠獲得更穩定的結果。除此之外，也首次引入了樣條函數來配飾資料並獲取特徵。雖然準確率稍微不及原始加速度以及傅立葉轉換的特徵，但也可以看到辨識類的最高平均準確度達到了 86% ，代表樣條函數來配適是未來值得再更深入研究的方法。同時，本次研究以統計的角度使用樣本獨立性 *t* 檢定來客觀驗證維度縮減在各個模型上的效用，並且相比於以往的論文更加進行了不同部位的比較，進行統計 ANOVA 分析，成功的使用變異數分析事後檢定來驗證出軀幹在三個部位之中的代表性。

為了驗證理論研究的可行性，並測試這些模型運用到真實生活中的情況，本次研究也將訓練完的模型整合成為一個應用程式，而這個應用程式也成功的在資料蒐集到儀器後，即時的預測以及辨識出了凝凍步態的發生，達到及時與準確的目的。經由以上一系列的研究與實作，我們認為將這個模型嵌入到穿戴式裝置是可行的，但考量到穿戴式裝置的體積較小且運算能力較差，未來的研究方向勢必需要往輕量型運算的方面進行。

6 參考資料

- [1] Pham, T. T., Moore, S. T., Lewis, S. J. G., Nguyen, D. N., Dutkiewicz, E., Fuglevand, A. J., et al. (2017). Freezing of Gait Detection in Parkinson's Disease: A Subject-Independent Detector Using Anomaly Scores. *IEEE Transactions on Biomedical Engineering*, 64(11), 2719-2728.
- [2] Kleanthous, N., Hussaina, A. J., Khana, W., Liatsis, P. (2020). A new machine learning based approach to predict Freezing of Gait. *Pattern Recognition Letters*, 140, 119-126.

- [3] Li, B., Yao, Z., Wang, J., Wang, S., Yang, X., Sun, Y. (2020). Improved Deep Learning Technique to Detect Freezing of Gait in Parkinson's Disease Based on Wearable Sensors. *Electronics*, 9(11): e1919.
- [4] Shalin, G., Pardoel, S., Julie Nantel, Lemaire, E. D., Kofman, J. (2020). Prediction of Freezing of Gait in Parkinson's Disease from Foot Plantar-Pressure Arrays using a Convolutional Neural Network. 2020 42nd Annual International Conference of the IEEE Engineering in Medicine Biology Society (EMBC), 244-247
- [5] J. D. Schaafsma, Y. Balash, T. Gurevich, A. L. Bartels, J. M. Hausdorff, and N. Giladi, "Characterization of freezing of gait subtypes and the response of each to levodopa in parkinson's disease," *European Journal of Neurology*, vol. 10, no. 4, pp. 391—398, 2003.
- [6] Pardoel, S., Shalin, G., Julie Nantel, Lemaire, E. D., Kofman, J. (2021). Prediction and detection of freezing of gait in Parkinson's disease from plantar pressure data using long short-term memory neural-networks. *Journal of NeuroEngineering and Rehabilitation*, 18(1): e167.
- [7] Mazilu, S., Calatroni, A., Gazit, E. and Roggen, D. Feature Learning for Detection and Prediction of Freezing of Gait in Parkinson's Disease, *Machine Learning and Data Mining in Pattern Recognition Conference*, 2013. DOI:10.1007/978-3-642-39712-7_11
- [8] Bachlin, M., Plotnik, M., Roggen, D., Maidan, I., Hausdorff, J. M., Giladi, N. and Troster, G., Wearable assistant for Parkinson's disease patients with the freezing of gait symptom, *IEEE Trans Inf Technol Biomed*, Vol. 14, no. 2, 436-46, 2010.